



**INSTITUTO FEDERAL**  
Ceará  
Campus Fortaleza



# Classificação Linear

Lucas de Oliveira Santos

[lucas.santos@lapisco.ifce.edu.br](mailto:lucas.santos@lapisco.ifce.edu.br)

## Assuntos abordados

- ⇒ Introdução
- ⇒ Fundamentos de Classificação
- ⇒ Classificadores e Métodos
- ⇒ Análise de Componentes Principais (PCA)

# Introdução

- ⇒ O que é aprendizado de máquina?
- ⇒ Reconhecimento de Padrões
- ⇒ Visão Computacional
- ⇒ Inteligência Computacional
- ⇒ Tomada de decisão

# Fundamentos de Classificação

- ⇒ A classificação é fundamental na área do aprendizado de máquina e o seu objetivo é atribuir um **rótulo** ou **classe** a um objeto qualquer. Isso é feito baseado nas **características** do objeto.
- ⇒ As **classes** ou **rótulos** representam as distintas **características** às quais os objetos pertencem. Logo, o objetivo de um classificador é aprender as relações existentes entre as **classes** e as **características** de objetos.

# Fundamentos de Classificação

- ⇒ Existem alguns tipos de classificação, como a binária, multiclases, dentre outras.
- ⇒ Classificação binária: tem como objetivo atribuir uma entre duas classes possíveis a cada exemplo de entrada.
  - Exemplo:
    - Determinar se um tumor cerebral é benigno ou maligno;
    - Determinar se um e-mail é um spam ou não;
- ⇒ Classificação multiclases: tem como objetivo atribuir uma entre várias classes possíveis a cada exemplo de entrada.
  - Exemplo:
    - Classificar imagens de dígitos escritos à mão em sua respectivas categorias;
    - Classificar textos ou documentos em categorias de tópicos, como esportes, saúde, tecnologia, dentre outros;

# Fundamentos de Classificação



a) Grupo 1



b) Grupo 2



c) Grupo 3

⇒ A qual dos grupos acima a imagem a seguir pertence ?



## Fundamentos de Classificação

- ⇒ A sua escolha foi baseada no **grau de semelhança** entre a fruta desconhecida e as frutas pertencentes aos grupos 1, 2 e 3 ?
- ⇒ Como seu cérebro faz essa atribuição de forma instintiva ?
- ⇒ Certamente ele faz uma **comparação** entre as frutas em questão !
- ⇒ O objetivo dos classificadores é replicar ao máximo esse mecanismo em uma máquina.

# Fundamentos de Classificação

⇒ Para realizar essas comparações, nosso cérebro precisa de alguns meios:

- **Representação** dos **atributos** ou **características** físicos(as) das frutas;
- **Memorização** das características aprendidas;
- **Regra de decisão** para **classificar** as frutas;
- Capacidade de **aprendizado** de novas frutas;



## Fundamentos de Classificação

⇒ Vamos elencar algumas características para as frutas do nosso caso de estudo:

- **Formato** - { esférico, oval, alongado } = { 0, 1, 2 };
- **Cor** - { amarelo, vermelho, alaranjado, verde, marrom } = { 0, 1, 2, 3, 4 };
- **Textura da casca** - { lisa, rugosa, espinhosa } = { 0, 1, 2 };
- **É uma fruta cítrica ?** - { não, sim } = { 0, 1 };
- **Possui um cheiro forte ?** - { não, sim } = { 0, 1, 2 };

⇒ Com relação à tangerina, ela é oval, alaranjada, rugosa, é cítrica e possui cheiro forte !

# Fundamentos de Classificação

- ⇒ Em termos computacionais, devemos atribuir valores numéricos para esses atributos, pois os computadores só entendem números.
- ⇒ Dessa forma, cada fruta (ou outro tipos de objetos) será representada como um vetor que contém cada um de suas características.

$$\blacksquare \quad \mathbf{x} = [x_1 \ x_2 \ \dots \ x_p]$$

# Fundamentos de Classificação

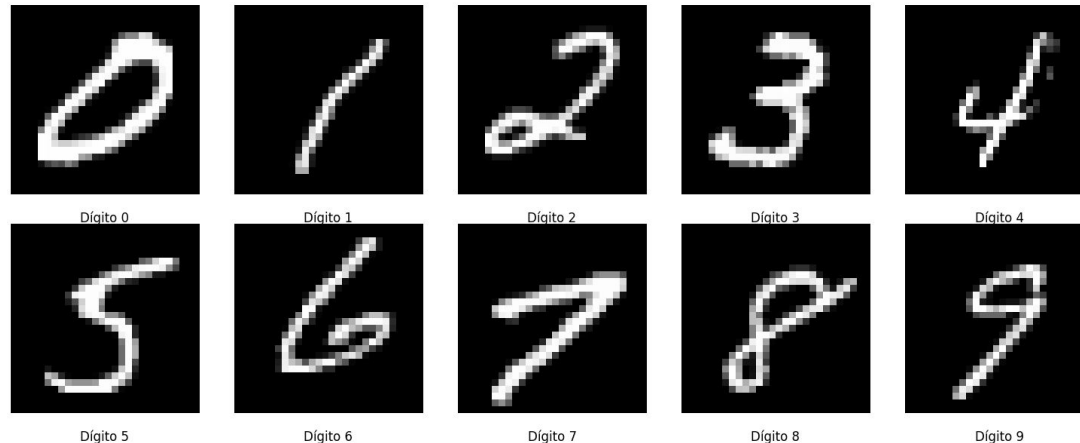
- ⇒ Podemos então representar numericamente os objetos da seguinte forma:
- **Objeto** Laranja:  $\mathbf{x} = [0\ 2\ 1\ 1\ 0]$ ;
  - **Objeto** Maçã:  $\mathbf{y} = [0\ 1\ 0\ 0\ 0]$ ;
  - **Objeto** Tangerina:  $\mathbf{z} = [0\ 2\ 1\ 1\ 1]$ ;
- ⇒ No contexto de imagens, um **objeto** pode ser entendido como qualquer **parte** de uma imagem a qual se possa extrair pelo menos uma **característica mensurável** que a torne **diferente** do restante.

# Classificadores e Métodos

- ⇒ Vamos trabalhar a abordagem de classificação em imagens.
- ⇒ Nesse sentido, iremos resumir o problema de classificação de padrões em um modelo de regressão linear, ao qual iremos aplicar o estimador de Mínimos Quadrados - MQO.
- ⇒ Podemos então associar as **classes** como sendo um vetor de resultados  **$y$**  e os pixels das imagens como as características dos objetos que queremos classificar.

# Classificadores e Métodos

- ⇒ Podemos estender a análise feita com as frutas para as imagens a seguir ?
- ⇒ Quais seriam as características que tornam os dígitos diferentes uns dos outros ?



## Classificadores e Métodos

- ⇒ Os atributos cor, tamanho e formato não podem ser efetivamente utilizados, pois os dígitos apresentam a mesma cor, um tamanho aproximado e alguns apresentam formatos parecidos.
- ⇒ Dessa forma, iremos considerar os pixels de cada número como sendo os atributos deles.

## Classificadores e Métodos

- ⇒ Iremos representar cada um desses dígitos como sendo um vetor com 10 posições (os números variam de 0 até 9). Esse método é chamado de “one-hot encoding” e é bastante usado para classificação com multi-rótulos. A imagem a seguir ilustra esse método.

$$\begin{bmatrix} C_1 \\ C_2 \\ \dots \\ C_q \end{bmatrix} = \begin{bmatrix} [1 \ 0 \ 0 \ \dots \ 0]^T \\ [0 \ 1 \ 0 \ \dots \ 0]^T \\ \dots \\ [0 \ 0 \ 0 \ \dots \ 1]^T \end{bmatrix}$$

- ⇒ Onde  $C_1$ ,  $C_2$ ,  $C_q$ , representam as classes e os vetores respectivos representam os rótulos numéricos de cada classe.

# Classificadores e Métodos

- ⇒ Os coeficientes  $\mathbf{W}$  são calculados usando-se o método MQO, que é dado pela expressão a seguir:

$$J(\beta_1, \beta_2, \dots, \beta_p) = \sum_{i=1}^n \varepsilon_i^n = \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{j,i} \right)^2$$

- ⇒ A função de soma dos quadrados é dada por:  $S(\beta_0, \beta_1, \dots, \beta_k) = \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2$

- ⇒ Ela pode ser decomposta em função das derivadas parciais de cada um dos coeficientes da seguinte forma:

$$\frac{\partial S(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)}{\partial \beta_0} = \sum_{i=1}^N -2 \cdot (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i,1} - \dots - \hat{\beta}_k x_{i,k}) = 0$$

$$\frac{\partial S(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)}{\partial \beta_1} = \sum_{i=1}^N -2 \cdot x_{i,1} \cdot (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i,1} - \dots - \hat{\beta}_k x_{i,k}) = 0$$

$$\frac{\partial S(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)}{\partial \beta_k} = \sum_{i=1}^N -2 \cdot x_{i,k} \cdot (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i,1} - \dots - \hat{\beta}_k x_{i,k}) = 0$$



## Classificadores e Métodos


- ⇒ A formulação matricial desses conceitos é importante do ponto de vista computacional.
- ⇒ Nesse sentido, o modelo de classificação multiclases é definido como:  $Y = WX$
- ⇒ A estimativa de MQO do ponto de vista matricial é dada pela minimização da expressão:  $e^T e = \sum_{i=1}^N e_i^2$ , sendo que  $e$  é dado por:  $e = Y - WX$ . Dessa forma, podemos reescrever a equação:  $e^T e = (Y - WX)^T (Y - WX)$
- ⇒ Por fim, a estimativa de MQO é dada por:  $W = (X^T X)^{-1} (X^T Y)$ . Essa equação é conhecida como o método da pseudo-inversa.

# Análise das Componentes Principais - PCA

- ⇒ Em muitas aplicações reais, quando o volume de dados não é bem refinado, o modelo de classificação ou regressão pode não ser bem sucedido.
- ⇒ Dentre os vários tipos de refinamento que podem ser aplicados nos dados, iremos abordar o refinamento de dimensionalidade.
- ⇒ Ocorre quando os dados apresentam muitas características em relação ao número de amostras existentes.
- ⇒ As principais problemáticas desse tipo de comportamento nos dados são:
  - Dados muito dispersos em altas dimensões;
  - Previsões erradas;
  - Agravamento do problema de **overfitting**;
  - Dificuldade de visualizar as relações entre as variáveis;
  - Aumento do custo computacional;

# Análise das Componentes Principais - PCA

- ⇒ Algumas características do PCA:
- É um método de **compressão de dados**, que foi utilizado primeiramente para comprimir dados de imagens e sinais.
  - Em **classificação de padrões**, o efeito mais vantajoso da aplicação do PCA é a **redução nas dimensões** dos dados.
  - O PCA aplica uma **transformação linear** nos dados.
- ⇒ A imagem a seguir é uma representação em diagrama de blocos de uma transformação linear.



# Análise das Componentes Principais - PCA

- ⇒ A equação de transformação linear do PCA é dada por:  $Z = QX$ 
  - $Z$  representa os dados transformados;
  - $Q$  é a matriz de transformação;
  - $X$  são os dados originais;
- ⇒ A equação de recuperação dos dados é dada por:  $X = Q^T Z$
- ⇒ Após aplicar a transformação nos dados, as dimensões continuam as mesmas, logo, não há redução.
- ⇒ Para entender melhor como a redução de dimensão ocorre, vamos relembrar o conceito de matriz de covariância.

# Análise das Componentes Principais - PCA

- ⇒ A **covariância** é uma medida estatística que nos diz como duas variáveis se **relacionam** entre si. Isso nos ajuda a entender se o aumento ou diminuição de uma provoca o mesmo tipo de comportamento na outra.
- ⇒ Se duas variáveis aumentam ou diminuem juntas, a **covariância** entre elas é dita positiva, caso contrário, ela é negativa.
- ⇒ A **matriz de covariância** é relevante para o problema de classificação com muitos dados porque ela nos ajuda a entender como as variáveis se relacionam umas com as outras. Ela é fundamental para utilização do PCA.
- ⇒ A fórmula da covariância é dada por: 
$$S_{xy} = \frac{\sum_{i=1}^n (x_i \bar{x})(y_i \bar{y})}{n - 1}$$

# Análise das Componentes Principais - PCA

⇒ Vejamos um exemplo da matriz de covariância na Tabela abaixo.

|          | $x_i$ | $y_i$ | $x_i - \bar{x}$ | $y_i - \bar{y}$ | $(x_i - \bar{x})(y_i - \bar{y})$ |
|----------|-------|-------|-----------------|-----------------|----------------------------------|
|          | 3     | 60    | -5              | 14              | -70                              |
|          | 4     | 50    | -4              | 4               | -16                              |
|          | 6     | 50    | -2              | 4               | -8                               |
|          | 11    | 40    | 3               | -6              | -18                              |
|          | 16    | 30    | 8               | -16             | -128                             |
| $\Sigma$ | 40    | 230   | —               | —               | -240                             |

⇒ Da tabela, temos que o valor da covariância **Sxy** = -60, logo os dados estão negativamente correlacionados. Isso indica que uma reta decrescente irá dividir os pontos.

# Análise das Componentes Principais - PCA

- ⇒ Para entender como a redução nos dados ocorre, precisamos assumir algumas premissas:
- A matriz de **covariância** dos dados transformados  $\mathbf{Z}$  é diagonal, ou seja, não existe correlação entre as componentes do vetor  $\mathbf{Z}$ ;
  - Os valores encontrados na diagonal da matriz  $\mathbf{Z}$  são iguais aos valores das variâncias da matriz original  $\mathbf{X}$ .
  - O cálculo das **variâncias** é dado por:  $\sigma_x^2 = (x_i - \bar{x})^2$ ,  $\sigma_y^2 = (y_i - \bar{y})^2$ , ...,  $\sigma_n^2 = (n_i - \bar{n})^2$
- ⇒ O PCA atua sobre os dados em  $\mathbf{X}$  para gerar um novo conjunto de dados  $\mathbf{Z}$ , cuja matriz de covariância é diagonal;

$$\mathbf{C}_{\mathbf{z}} = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \lambda_p \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \sigma_p^2 \end{bmatrix}$$

## Análise das Componentes Principais - PCA

- ⇒ Do exposto, agora podemos entender a redução de dimensionalidade que o PCA provoca nos dados com o conceito de **Variância Total (VL)**.

$$VT = \sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2$$

- ⇒ A matriz diagonal obtida anteriormente possui os valores das variâncias dos dados originais,  $(\sigma^1, \sigma^2, \dots)$ . Esses valores representam porcentagens diferentes dos dados.
- ⇒ Para redução de dimensionalidade, deve-se primeiramente ordenar os valores de  $\sigma$  do maior para o menor. Após isso, podemos criar uma medida de quanto da informação do conjunto original está sendo representada ao escolhermos os  $q$  primeiros  $\sigma$ .



## Conclusões

- ⇒ O PCA é uma transformação linear que é aplicada aos dados de entrada;
- ⇒ As variâncias das variáveis transformadas são iguais as variâncias dos dados originais;
- ⇒ O PCA provoca uma rotação no plano original dos dados de de forma a garantir que os eixos que contenham a maior variabilidade dos dados;

## Referências

- ⇒ [1] W. Hines, D. Montgomery, D. Goldsman, and C. Borror, “Probabilidade e estatística na engenharia, 4a edição, ed,” LTC, Rio de Janeiro-RJ, 2006.
- ⇒ [2] O. Helene, Métodos dos Mínimos Quadrados. Editora Livraria da Física, 2006.
- ⇒ [3] A. E. Hoerl and R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” Technometrics, vol. 12, no. 1, pp. 55–67, 1970.
- ⇒ [4] D. Astolfi and R. Pandit, “Multivariate wind turbine power curve model based on data clustering and polynomial lasso regression,” Applied Sciences , vol. 12, no. 1, p. 72, 2021.
- ⇒ [5] S. Shokrzadeh, M. J. Jozani, and E. Bibeau, “Wind turbine power curve modeling using advanced parametric and nonparametric methods,” IEEE Transactions on Sustainable Energy , vol. 5, no. 4, pp. 1262–1269, 2014.
- ⇒ [6] A. E. Hoerl and R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” Technometrics , vol. 12, no. 1, pp. 55–67, 1970.

# Obrigado pela atenção!

## Dúvidas?

Lucas de Oliveira Santos

[lucas.santos@lapisco.ifce.edu.br](mailto:lucas.santos@lapisco.ifce.edu.br)